De Células a Clústeres

Introducción al Análisis de Single-Cell RNA-seq en Python

Dra. Cristal Villalba Silva · UT Health San Antonio

ISCB-LATAM SolBio SPBBC 2026 · Lima, Perú · 9 de noviembre de 2026

github.com/Kur1sutaru/ISMB-LATAM

El plan de hoy

9:00	Introducción (diapositivas)
9:20	00 · Cell Ranger y AnnData
9:40	01 · Control de calidad
10:15	02 · PCA, UMAP, clustering
10:45	Pausa para café
11:00	03 · Anotación de tipos celulares
11:35	04 · Gráficos, DEGs, vías
12:05	05 · Integración · R vs Python

~65 % práctico en Google Colab · materiales en inglés y español

A las 12:30 podrás…

- Pasar de una matriz de Cell Ranger a un objeto AnnData
- Eliminar células de baja calidad y dobletes, normalizar
- Reducir dimensiones, construir UMAPs, agrupar células
- Anotar tipos celulares con marcadores, bases de datos y atlas
- Hacer figuras claras, encontrar DEGs, interpretar vías
- Integrar muestras, comparar condiciones, traducir a R

¿Por qué single-cell? Batido vs. ensalada de frutas



RNA-seq bulk

- Un perfil promedio por muestra
- Un cambio puede ser de expresión o de composición celular, y no se puede distinguir
- Las células raras (< 5 %) son invisibles
- Barato, profundo, muchas réplicas



Single-cell RNA-seq

- Un perfil por célula: de miles a millones de células
- Descubrir tipos y estados celulares, incluso raros
- Medir composición y respuestas específicas de cada tipo
- Disperso (la mayoría de valores son 0), ruidoso, más caro

Principales tecnologías

Gotas

10x Chromium, Drop-seq. 1k–20k células por canal, conteos 3' o 5' con UMIs. La opción más común.

Placas

Smart-seq2/3. Cientos de células, transcritos completos: isoformas, mutaciones, alta sensibilidad.

Indexado combinatorio

SPLiT-seq, Parse, sci-RNA-seq. Hasta millones de células y muchas muestras, células fijadas.

Espacial

Visium HD, Xenium, MERFISH, CosMx. Expresión con su posición en el tejido.

El single-nucleus RNA-seq (snRNA-seq) funciona con tejido congelado y células difíciles de disociar (neuronas, adipocitos); el análisis es casi idéntico.

Cómo funciona 10x Chromium

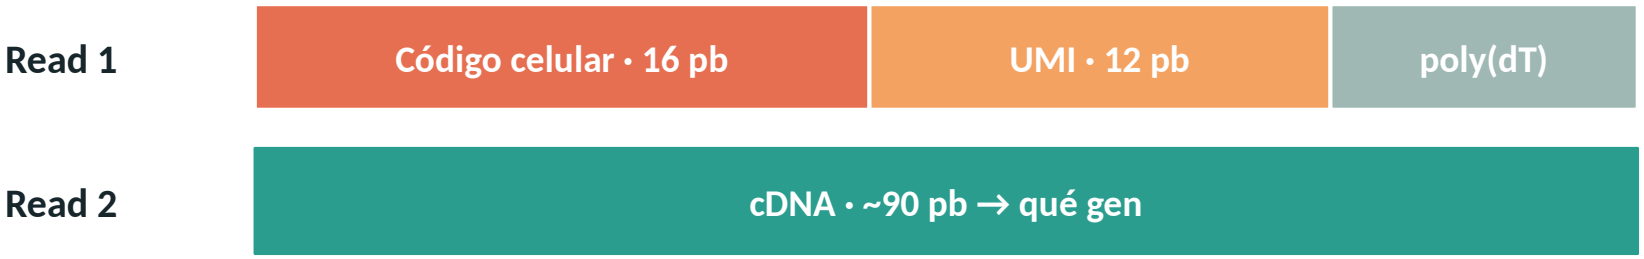
1 · Encapsular
Célula + perla con códigos en una gota de aceite (GEM)

2 · Lisar y marcar
mRNA capturado por poli(dT); cada molécula recibe código celular + UMI

3 · Juntar y amplificar
Romper gotas, transcripción reversa, PCR, construir la biblioteca

4 · Secuenciar
Illumina paired-end, ~20–50k lecturas por célula

Estructura de las lecturas (3' v3/v4)



Código → qué célula

UMI → qué molécula (elimina duplicados de PCR)

cDNA → qué gen

Cell Ranger: de FASTQ a matriz de conteos

Alinear
STAR al genoma + anotación

Códigos
Corregir contra la lista de 10x

Contar UMIs
Mismo código + UMI + gen = 1 molécula

Identificar células
Separar células de gotas vacías

```
cellranger count --id=sample1 \
  --transcriptome=refdata-gex-GRCh38-2024-A \
  --fastqs=fastqs/ --sample=sample1 --create-bam=true
```

Necesita un servidor Linux (≥ 64 GB de RAM), no Colab. Una ejecución por muestra; usa cellranger multi para bibliotecas multiplexadas o multimodales.



Alternativas abiertas

- STARsolo
- alevin-fry / simpleaf
- kallisto | bustools
- Más rápidas, gratuitas, en cualquier servidor

Lo que te entrega Cell Ranger

Archivo en outs/	Úsalo para
web_summary.html	Reporte de calidad: ábrelo siempre primero
filtered_feature_bc_matrix(.h5)	Conteos de células identificadas → nuestro análisis
raw_feature_bc_matrix(.h5)	Todos los códigos → eliminar RNA ambiental
metrics_summary.csv	Comparar muestras
possorted_genome_bam.bam	Velocidad, genotipado (rara vez)
cloupe.cloupe	Exploración en Loupe Browser

Revisa en web_summary.html

> 70 %

lecturas en células

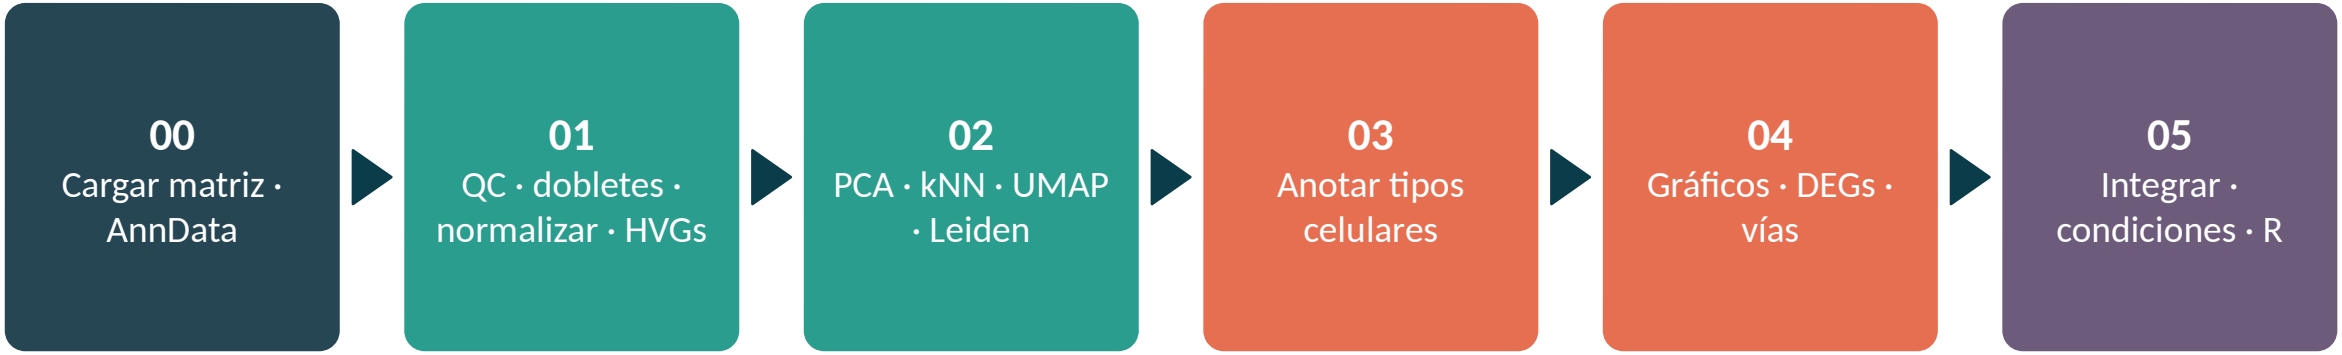
> 60 %

lecturas mapeadas al transcriptoma

≥ 1,000

mediana de genes por célula (según tejido)

El flujo que seguimos hoy



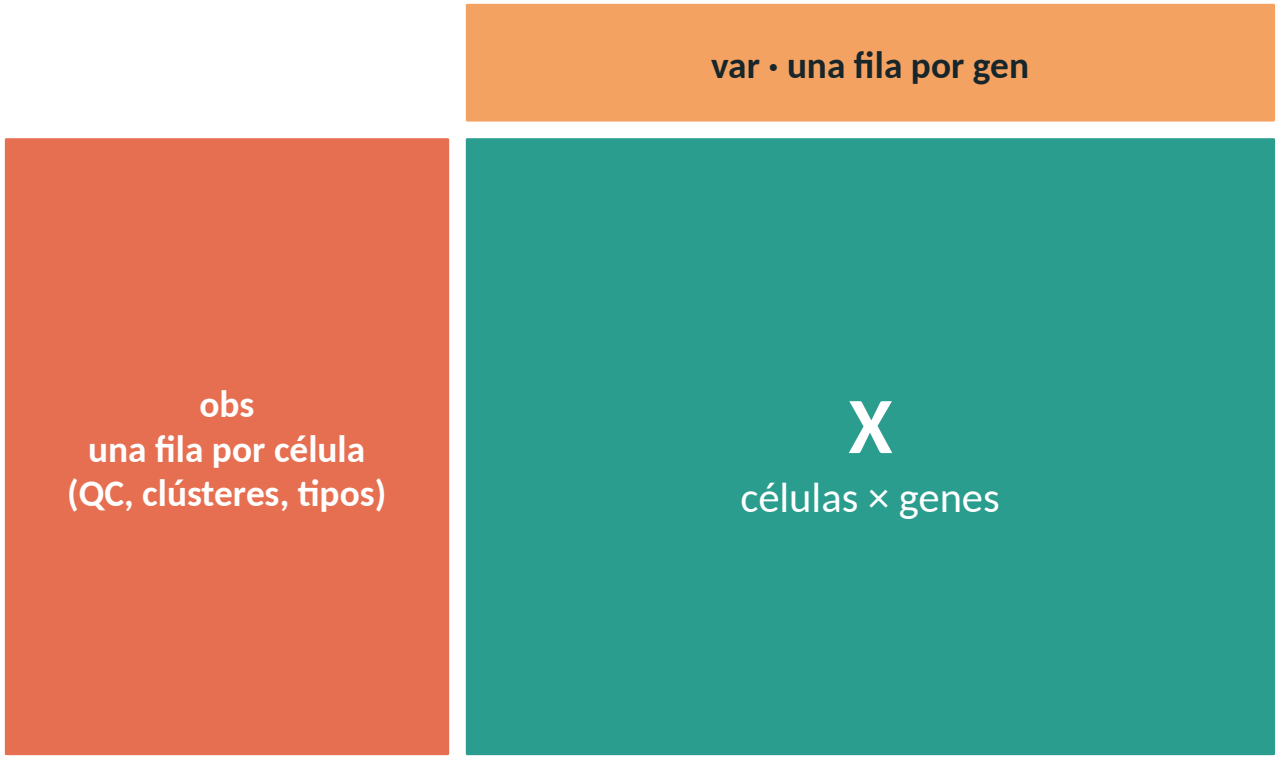
Datos

- PBMC 3k (10x): 2.700 células de sangre, donante sano → notebooks 00–04
- Kang 2018: 8 donantes, control vs IFN-β → notebook 05

Herramientas (scverse)

- Scanpy + AnnData para el análisis central
- decoupler, CellTypist, harmonypy, BBKNN, PyDESeq2

AnnData: un objeto para todo



`adata.layers`
otras matrices de igual forma (conteos crudos)

`adata.obsm`
embeddings por célula (X_pca, X_umap)

`adata.obsp`
grafos célula–célula (vecinos)

`adata.uns`
todo lo demás (colores, parámetros, resultados de DE)

`adata.raw`
copia fija de los datos log-normalizados, todos los genes

Se guarda como .h5ad · Equivalentes en R: Seurat, SingleCellExperiment

01 · Control de calidad: no todo código es una buena célula

Células muriendo / rotas

Pocos genes, alto % de lecturas mitocondriales. Filtrar por % MT y mín. de genes.

Dobletes

Dos células en una gota: demasiados UMIs y marcadores mezclados. Detectar con Scrublet / scDblFinder.

RNA ambiental

mRNA libre en todas las gotas. Corregir con SoupX, CellBender, scAR.

Elegir umbrales

Cortes fijos (p. ej. 200–2.500 genes, < 5 % MT para PBMCs) o basados en los datos: > 5 MADs de la mediana. El tejido importa: neuronas y cardiomiocitos tienen naturalmente alto % MT. Reporta siempre lo que usaste.

01–02 · De conteos a un espacio de baja dimensión

Conteos crudos
~30k genes, profundidad distinta por célula

Normalizar + log
conteos por 10k → log(x+1)

HVGs
conservar ~2.000 genes informativos

PCA
~30 ejes capturan la biología

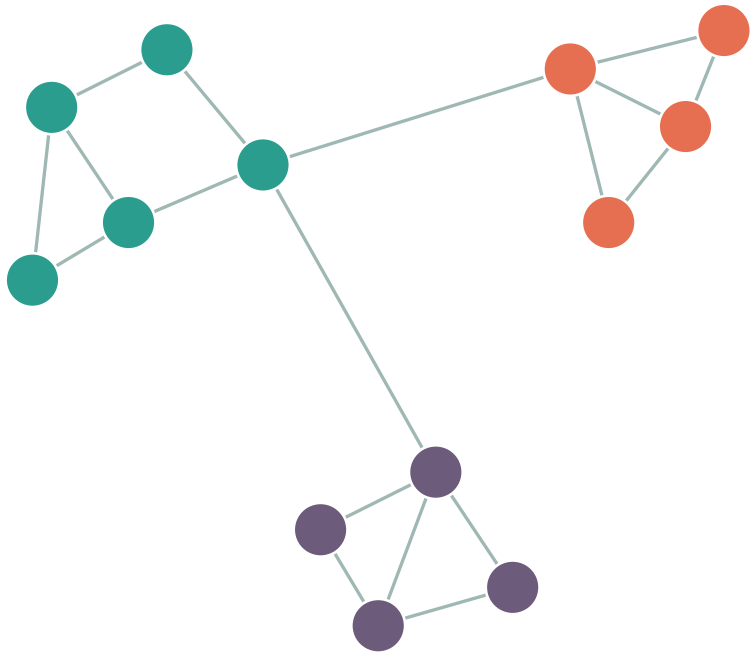
¡Guarda los conteos crudos!

- adata.layers["counts"] antes de normalizar
- El DE pseudobulk y scVI necesitan enteros
- Alternativas: scran, residuos de Pearson, SCTransform

¿Cuántos PCs?

- Busca el codo en el gráfico de varianza
- Unos pocos de más es más seguro que de menos
- PBMC 3k: codo ~10–15, usamos 30

02 · Vecinos, UMAP y clustering con Leiden



Grafo kNN: cada célula unida a sus 15 células más parecidas; Leiden encuentra comunidades densamente conectadas

UMAP es un dibujo, no una medición

- Se conservan los vecindarios locales
- Las distancias entre clústeres y sus tamaños no son confiables

La resolución es una elección

- Mayor resolución → más clústeres, más pequeños
- Compara varias (0,3, 0,8, 1,5) y guíate por la biología

03 · Tres formas de nombrar tus clústeres

Manual · genes marcadores

- rank_genes_groups → genes top por clúster
- Comparar con marcadores conocidos (dot plot)
- Transparente, usa tu experiencia

Bases de marcadores

- PanglaoDB, CellMarker 2.0
- Puntuar cada célula (ULM de decoupler)
- Rápido, pero listas genéricas

Referencias y clasificadores

- CellTypist, sc.tl.ingest, scANVI
- R: SingleR, Azimuth
- Reproducible; no encuentra tipos nuevos

Combínalos: la concordancia entre métodos independientes es tu evidencia; las discrepancias te dicen dónde mirar con más cuidado.

03 · Dónde encontrar referencias y registrar anotaciones

PanglaoDB

Marcadores curados, humano y ratón · panglaodb.se

CZ CELLxGENE

> 100 M células estandarizadas; Explorer, Gene Expression, API Census

Single Cell Portal

Broad Institute: cientos de estudios, gráficos y descargas

Cell Annotation Platform

CAP · celltype.info: registra etiquetas con evidencia y compártelas

CellTypist

Clasificadores preentrenados: inmune, pulmón, intestino, cerebro…

Cell Ontology

IDs estándar (CL:0000236 = célula B) que hacen reutilizables las etiquetas

04 · Elige el gráfico según la pregunta

Gráfico	Pregunta que responde	Scanpy
UMAP	¿Dónde están los tipos celulares? ¿Dónde se expresa el gen X?	sc.pl.umap
Violin / stacked violin	¿Cómo se distribuye un gen en cada grupo?	sc.pl.violin, sc.pl.stacked_violin
Dot plot	Muchos marcadores × grupos: % que expresa y nivel medio	sc.pl.dotplot
Matrix plot / heatmap	Medias compactas, o heterogeneidad célula a célula	sc.pl.matrixplot, sc.pl.heatmap
Barras de proporción	¿Cómo cambia la composición entre muestras?	pandas + matplotlib
Volcano plot	¿Qué genes cambian, cuánto y con qué significancia?	matplotlib / decoupler

Consejos: paletas seguras para daltonismo (viridis), etiquetas sobre los datos, vmax="p99" para controlar valores extremos, guarda en PDF/SVG.

04–05 · Expresión diferencial: ¿qué prueba?

Marcadores entre clústeres

- Wilcoxon por célula: rank_genes_groups
- Útil para describir y anotar clústeres
- Los p-valores son optimistas: los genes se usaron para formar los clústeres

Condiciones (enfermedad vs. control)

- Pseudobulk: sumar conteos por muestra × tipo celular
- DESeq2 / edgeR con el donante como réplica
- Necesita ≥ 3 réplicas biológicas por condición

Las células de una persona no son réplicas independientes. Tratarlas así produce miles de falsos positivos (Squair et al. 2021).

04 · ¿Qué significan los genes?

Sobrerrepresentación (ORA)

- DEGs top vs. conjuntos de genes (prueba de Fisher)
- MSigDB Hallmark, GO, Reactome
- Simple; depende de un corte

Actividad de vías

- Huellas de PROGENy: genes blanco con peso
- Puntaje por célula o por contraste (ULM)
- Usa dirección e intensidad

Firmas génicas

- Cualquier lista de un artículo
- sc.tl.score_genes por célula
- p. ej. respuesta a interferón

Más allá de hoy: comunicación célula–célula (LIANA+, CellChat), trayectorias (PAGA, scVelo, CellRank), actividad de TFs (CollecTRI), espacial (Squidpy).

05 · Integración: alinear muestras, conservar la biología

Método	Trabaja sobre	Fortalezas	Lenguajes
Harmony	PCA	Rápido, simple, buena opción por defecto	R · Python
BBKNN	Grafo kNN	Muy rápido; solo grafo (clustering, UMAP)	Python
scVI / scANVI	Conteos crudos	Lotes complejos, atlas; transferencia de etiquetas; GPU	Python
Seurat CCA / RPCA	Anclas	Bien documentado, muy usado	R



Mezcla de lotes ↑

Células del mismo tipo de distintas muestras son vecinas



Conservación biológica ↑

Los distintos tipos celulares siguen separados (métricas scIB)

¿R o Python? Ambos, y puedes moverte entre ellos

Paso	Python (scverse)	R (Seurat / Bioconductor)
Objeto	AnnData (.h5ad)	Seurat (.rds) · SingleCellExperiment
QC · doublets	calculate_qc_metrics · scrublet	PercentageFeatureSet · scDblFinder
Normalizar · HVG	normalize_total + log1p · highly_variable_genes	NormalizeData / SCTransform · FindVariableFeatures
Grafo · clústeres	neighbors · leiden · umap	FindNeighbors · FindClusters · RunUMAP
Marcadores	rank_genes_groups	FindAllMarkers
Anotación	CellTypist · ingest · scANVI	SingleR · Azimuth
DE pseudobulk	decoupler + PyDESeq2	muscat · DESeq2 · edgeR

Convertir: zellkonverter::readH5AD() · anndata2ri · rpy2. Los valores por defecto difieren: resultados parecidos, no idénticos.



Python

Millones de células, GPUs, aprendizaje profundo (scvi-tools), pipelines de ML



R

Estadística de Bioconductor, muchos métodos especializados, viñetas pulidas

Empecemos: Google Colab en 4 pasos

1 · Abrir
github.com/Kur1sutaru/ISMB-LATAM → Abrir en Colab

2 · Copiar
Archivo → Guardar una copia en Drive

3 · Configurar
Ejecuta la primera celda de código (~1 min)

4 · Ejecutar
Shift + Enter, celda por celda, en orden

Para tener en cuenta

- 🟢 Core = en vivo · 🔎 Extra = estudio individual
- Cada notebook reconstruye el paso anterior si es necesario
- USE_DRIVE = True guarda resultados en Drive

Si algo falla

- Entorno de ejecución → Reiniciar sesión y ejecutar todo
- "Google no creó este notebook" → Ejecutar de todos modos
- Levanta la mano: hay ayudantes en la sala

Sigue aprendiendo

Single-cell best practices

sc-best-practices.org

Tutoriales de Scanpy y scverse

scanpy.readthedocs.io · scverse.org

OSCA (Bioconductor) · Seurat

bioconductor.org/books/release/OSCA · satijalab.org/seurat

Galaxy Training Network

sección single-cell, sin código

Comunidad

ISCB-LATAM, Regional Student Groups de ISCB (RSG-Brasil, RSG-Peru…)

Estos materiales

github.com/Kur1sutaru/ISMB-LATAM

¡Gracias! Thank you! Obrigada!

Preguntas, comentarios, errores: abre un issue en GitHub

github.com/Kur1sutaru/ISMB-LATAM

Dra. Cristal Villalba Silva · ORCID 0000-0003-0283-7982

Código: MIT · Diapositivas y textos: CC BY 4.0